

编译原理大作业

Deadline :

2022 年 11 月 13 日 11 : 59PM (GMT+8)

一、目标

1、背景知识介绍

C-- 语言是本实验的源语言。是一个 c 语言的子集，C-- 语言是单文件的，以 .sy 作为后缀，去除了 C 语言中的 include/define/pointer/struct 等较复杂特性。

LLVM 是一个模块化的、可重用的编译器和工具链的集合，目的是提供一个现代的、基于 SSA 的、能够支持任意静态和动态编译的编程语言的编译策略。在最近几年已经成为表现上能够和 gcc 对标的项目。

LLVM IR 是 LLVM 项目中通用的中间代码，作为源语言和体系架构的连接部分，是学生需要从源语言中编译并翻译到的目标语言。

2、大作业要求

本次大作业要求编写一个编译器前端（包括词法分析器、语法分析器、语义分析及中间代码生成），(1)【必做任务】使用自动机理论编写词法分析器，(2)【必做任务】自上而下或者自下而上的语法分析方法编写语法分析器。(3)【选做任务】补充完成中间代码生成部分代码。

1、【必做任务】编写 C-- 语言的词法分析器，理解词法分析器的工作原理，熟练掌握基于自动机理论的词法分析器的工作流程。编写源代码识别输出单词的二元属性，填写符号表。

2、【必做任务】编写 C-- 语言的语法分析器，理解自上而下/自下而上的语法分析算法的工作原理；理解词法分析与语法分析之间的关系。语法分析器的输入为 C-- 语言源代码，输出为按扫描顺序进行推导或归约的正确/错误的判别结果，以及按照最左推导顺序/规范规约顺序生成语法树所用的产生式序列。

3、【选做任务】补全给出的中间代码生成部分代码。将编译器的前端与我们提供的编译器中端衔接，该部分需要遍历语法分析器生成的语法树，访问语法树结点并调用我们所提供的中端代码(见附录 2.2)，最终输出中间代码。

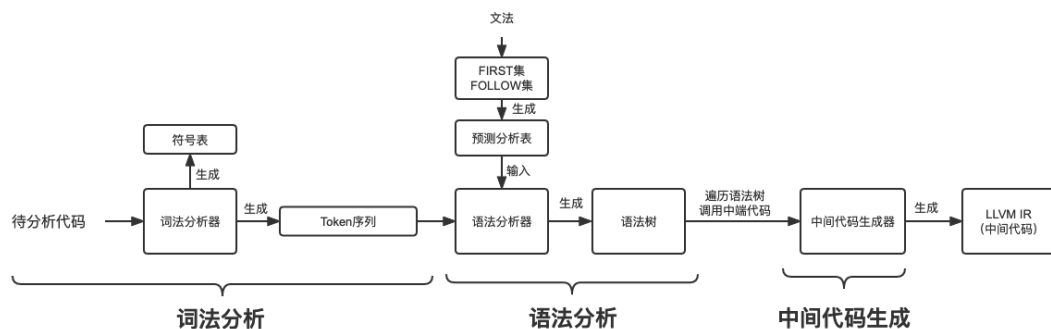


图 1: 整体流程图

二、软件需求

1、词法分析器

(1) 完成 C-- 语言的词法分析器，要求采用课程教授方法，实现有限自动机**确定化，最小化**算法。词法分析器的输入为 C-- 语言源代码，输出识别出单词的二元属性，填写符号表。单词符号的类型包括关键字，标识符，界符，运算符，整数，浮点数，字符串。每种单词符号的具体要求如下：

关键字 (KW, 不区分大小写) 包括： (1) int (2) void (3) return (4) const (5) main

运算符 (OP) 包括： (6) + (7) - (8) * (9) / (10) % (11) = (12) > (13) < (14) == (15) <= (16) >= (17) != (18) && (19) ||

界符 (SE) 包括： (20) ((21)) (22) { (23) } (24) ; (25) ,

标识符 (IDN) 定义与 C 语言保持相同，为字母、数字和下划线 () 组成的不以数字开头的串¹

整数 (INT) 的定义与 C 语言类似，整数由数字串表示

(2) 实现语言：C/C++/Java/Python. **注意：中端代码为 C++ 编写，若决定做选做部分，推荐首选 C++。**

(3) 操作目的：生成符号表；将源代码转化为单词符号序列。

2、语法分析器

(1) 完成 C-- 语言的语法分析器，语法分析器的输入为 C-- 语言代码的单词符号序列，输出用最左推导或规范规约产生语法树所用的**产生式序列**。C-- 语言文法须包含以下操作：

注意：具体语法和需实现的功能参见附录 1 提供的文法

- ① 常量定义的声明 (int a;)
- ② 常量定义的初始化 (int a = 3;)
- ③ 常类型数据的声明和定义 (const int a = 3;)
- ④ 变量赋值传递 (已声明的情况) (a = 3;/a = b;)
- ⑤ 函数名称，返回值类型，函数内部建立初始基本块并插入返回指令 (int add(...))
- ⑥ 函数传入参数的创建，管理 (int add(int a, int b))
- ⑦ 一元运算表达式 (加法和乘法), (int a = 3 + 4; int c = a * b;)
- ⑧ 单目运算符和变量数值结合 (+/-/!) (!0/ -3)
- ⑨ 复合运算表达式 (多个一元表达式结合 a = (b + c) * d)
- ⑩ 大小比较 (>/ >= / </ <=)
- ⑪ 双目运算符 (|| && <= == !=)

例如：采用 LL (1) 语法分析方法构建语法分析器需要完成以下内容：

- ① FIRST 集合、FOLLOW 集合；
- ② 对待编译代码规约使用的产生式序列。

(2) 实现语言：C/C++/Java/Python. **注意：中端代码为 C++ 编写，若决定做选做部分，推荐首选 C++。**

3、中间代码生成

(1) LLVM IR 具有三种表示形式，这三种中间格式是完全等价的：

- 1：在内存中的编译中间语言（我们无法通过文件的形式得到）
- 2：在硬盘上存储的二进制中间语言（格式为 .bc）

3: 人类可读的代码语言 (格式为 .ll)

本次实验要求输出 .ll 形式的 LLVM IR。

(2) 中间代码生成器代码补全: 对给出的中间代码生成器部分代码的缺失部分, 即各个结点的 visitor 函数进行补全。针对每个结点构造一个 visitor 函数来调用中端代码类(见附录 2.2), 其中 visit 函数对应于图一中语法分析和中间代码生成的衔接部分。

```
//varDef : bType Ident '=' initVal #initVarDef
//本例子展示一个 int 类型全局变量声明+初始化 (例: int a = 10 ; ) 的中间代码生成过程的伪代码
//对变量类型, 变量名和变量取值的初始化
1 Type type = i32_Type;
2 string var_name = "";
3 int data = 0;
//InitVarDefContext *ctx 是 AST 的对应结点
4 visitInitVarDef(InitVarDefContext *ctx) {
//访问子结点
5 visitChildren(ctx);
//s 为符号表, 其中 s.variable() 可以调用该结构存储变量
6 map<string, Value*> VariableCollection = s.variable();
//end() 函数表示遍历完变量的集合, 没有找到相同命名的变量
7 if(VariableCollection.find(var_name) != VariableCollection.end()) cout << " 重复命名" << endl;
//判断该变量是否为全局变量
8 if(ctx.isGlobal){
//调用中端的 GlobalVariable 函数, 生成该全局变量声明和初始化过程的中间代码
//参数说明: var_name(变量名), m(模块, 一个源代码文件的抽象表达, 参考附录 2.2 中的 Module 类), i32_Type(数据类型), false(判定是否是常量变量, 是否有 const 关键字), ConstantInt::get(data, m)(将初始化的数据存储)
9 GlobalVariable*gv=GlobalVariable::create(var_name,m,i32_Type,false, ConstantInt::get(data, m));
//将变量名和中间代码存储到符号表 s 中
10 s.put(var_name, gv);
11 }
12 return nullptr;
13 }
```

代码 1 VarDef Visitor 函数(部分)伪代码示例 (全局变量声明和初始化)

```

1  visitChildren(ParseTree *ctx) {
2  for(int i=0;i< (int)ctx->children.size(); i++){
    //children.size()得到 ctx 节点的子节点数
    //访问 bType 子结点获取变量类型
3  if(ctx->children[i]->type == "bType"){
4      visitBType(ctx->children[i]);
5  }
    //访问 ident 子结点获取变量名
6  else if(ctx->children[i]->type == "Ident"){
7      visitIdent(ctx->children[i]);
    //访问 initVal 子结点获取变量的值，该过程(根据文法)涉及层层调用，为了方便理解直接写为访问存放数据的
    Number 结点
8  }else if(ctx->children[i]->type == "initVal"){
9      visitNumber(ctx->children[i]);
10 }
11 }return nullptr;
12 }
13 visitBType(ParseTree *ctx) {
14 type = ctx->getText();
15 }
16 visitIdent(ParseTree *ctx) {
17 var_name = ctx->getText();
18 }
19 visitNumber(NumberContext *ctx) {
20 data = ctx->getText();
21 }

```

代码 2 visit 子结点代码示例

(3) 实现语言：C++；

(4) 操作目的：完成对语法分析生成的抽象语法树的遍历，并通过访问语法树结点来调用我们提供的中端代码（见附录 2.2），生成 LLVM IR 中间代码。

三、输出示例

1、词法分析输出示例

```
int a = 10;
int main(){
    a=10;
    return 0;
}
```

代码 3 待测 C--代码

(1) 【必须按规定格式输出】输出单词符号序列：

单词符号输出格式：

[待测代码中的单词符号] [TAB] <[单词符号种别],[单词符号内容]>

其中，单词符号种别为 KW（关键字）、OP（运算符）、SE（界符）、IDN（标识符）INT（整形数）；单词符号内容第一个维度为其种别，第二个维度为其属性。

```
int <KW,1>
a <IDN,a>
= <OP,11>
10 <INT,10>
; <SE,24>
int <KW,>
main <KW,5>
( <SE,20>
) <SE,21>
{ <SE,22>
a <IDN,a>
= <OP,11>
10 <INT,10>
; <SE,24>
return <KW,3>
0 <INT,0>
; <SE,24>
} <SE,23>
```

代码 4 单词符号序列示例

2、语法分析输出示例（以预测分析为例）

(1) 【必须按规定格式输出】输出规约序列（此处仅展示一部分）：

输出格式：

[序号] [TAB] [栈顶符号]#[面临输入符号] [TAB] [执行动作]

其中，选用规则序号见附件文法规则；执行动作作为“reduction”（LL 中的推到或 LR 中的归约），“move”（LL 分析的跳过或 LR 分析的移进），“accept”（接受）或“error”

```
1 program#int reduction
2 compUnit#int reduction
3 decl#int reduction
4 valDecl#int reduction
5 btype#int reduction
6 int#int move
7 varDef#a reduction
8 Ident#a move
9 != move
10 initVal#10 reduction
...
```

（错误）。

代码 5 归约序列部分输出示例

注：分析栈左端为栈顶，输入串过长没有在输出实例中进行展示，输入串即词法分析器生成的单词符号序列。

3、中间代码输出示例

```
; ModuleID = 'sysy2022_compiler'
source_filename = "../input/01_var_defn.sy"
@a = global i32 0
declare i32 @getint()
declare i32 @getch()
declare i32 @getarray(i32*)
declare void @putint(i32)
declare void @putch(i32)
declare void @putarray(i32, i32*)
declare void @starttime()
declare void @stoptime()

define i32 @main() {
main_ENTRY:
    %op0 = load i32, i32* @a
    store i32 %op0, i32 10
    ret i32 0
}
```

代码 6 中间代码输出示例

四、提交要求

1、源代码

包括词法分析器、语法分析器、对中端调用的部分

2、开发报告

对项目的开发过程进行详细的描述，包括（1）词法分析器算法描述，输出格式说明，源程序编译步骤；（2）语法分析器的算法描述，创建的分析表（预测分析表、LR 分析表等），输出格式说明，源程序编译步骤。（3）存储，遍历语法树的过程算法伪代码，以及调用中端的过程的算法设计思想。

3、测试报告

在给定的测试用例上分析后词法分析器以及语法分析器的输出截图（**注意需要按照要求格式输出**）。

五、注意事项：

- （1）采用附录中给出的文法编写程序。
- （2）不得借助 Lex/Yacc, ANTLR 等编译器自动生成工具。
- （3）所有出现在报告、代码、展示 PPT 中的内容，若非原创，需要明确标明内容来源，并给出正规的引用。未标明引用而采纳他人内容的情况，**视为抄袭**，遵照天津大学相关条例处理。
- （4）小组内各位组员需合理分工配合完成大作业，每位组员对项目的贡献可明确区分。PPT 展示时需明确每位组员负责完成的工作内容。

附录

1、文法文件

文法规则格式如下：

[序号] . [TAB] [产生式头部] [空格] -> [空格] [产生式体]

注：文法中出现的\$代表 ϵ ，文法中出现的 IDN（标识符）、INT（整数）参照词法分析器中定义，所有的关键字、界符、运算符均以原本形式存在。

C--文法：

1. Program -> compUnit;
2. compUnit -> (decl | funcDef)* EOF;
3. decl -> constDecl | varDecl;
4. constDecl -> 'const' bType constDef (',' constDef)* ';' ;
5. bType -> 'int';
6. constDef -> Ident '=' constInitVal;
7. constInitVal -> constExp
8. varDecl -> bType varDef (',' varDef)* ';' ;

```

9.  varDef ->
    Ident
    | Ident '=' initVal ;
10. initVal -> exp;
11. funcDef -> funcType Ident '(' (funcFParams)? ')' block;
12. funcType -> 'void' | 'int' ;
13. funcFParams -> funcFParam (',' funcFParam)*;
14. funcFParam -> bType Ident;
15. block -> '{' (blockItem)* '}';
16. blockItem -> decl | stmt;
17. stmt ->
    lVal '=' exp ';'
    | (exp)? ';'
    | block
    | 'return' (exp)? ';' ;
18. exp -> addExp;
19. cond -> lOrExp;
20. lVal -> Ident;
21. primaryExp ->
    '(' exp ')'
    | lVal
    | number;
22. number -> IntConst ;
23. unaryExp ->
    primaryExp
    | Ident '(' (funcRParams)? ')'
    | unaryOp unaryExp;
24. unaryOp -> '+' | '-' | '!';
25. funcRParams -> funcRParam (',' funcRParam)*;
26. funcRParam -> exp;
27. mulExp ->
    unaryExp
    | mulExp ('*' | '/' | '%') unaryExp ;
28. addExp -> mulExp # add1 | addExp ('+' | '-') mulExp;
29. relExp ->
    addExp
    | relExp ('<' | '>' | '<=' | '>=') addExp;
30. eqExp ->
    relExp
    | eqExp ('==' | '!=') relExp;
31. lAndExp ->
    eqExp
    | lAndExp '&&' eqExp;
32. lOrExp ->
    lAndExp
    | lOrExp '||' lAndExp;
33. constExp -> addExp;
34. IntConst -> [0-9]+ ;
35. Ident -> [a-zA-Z_][a-zA-Z_0-9]*;

```

2、LLVM 相关内容

2.1 LLVM 语法格式介绍：

<https://llvm.org/docs/LangRef.html> - void-type

2.2 中端代码链接：

<https://gitee.com/happy-traveller/compiler>